



# Matemática Computacional

## Aula 5 - Interpolação polinomial

Ricardo Moura



# Definição de desvio

## Definition

Dispondo de  $n$  pares ordenados  $(x_i, y_i)$  de números reais e de uma função  $g(x)$ . uma função de ajustamento aos pontos dados, chama-se **desvio** na abscissa  $x_i$  a

$$d(x_i) = d_i = y_i - g(x_i)$$

Vários critérios de ajustamento baseiam-se na minimização da soma destes desvios.

# Crítério dos mínimos quadrados: caso discreto

Este método consiste em achar uma função de ajustamento,  $g(x)$  a uma série de  $n$  pares ordenados  $(x_i, y_i)$ , minimizando

$$R_g = \sum_{i=1}^n (y_i - g(x_i))^2.$$

Para o mesmo número  $n$  de pares de ordenados,  $g(x)$  terá melhor ajustamento que  $h(x)$  se

$$R_g < R_h$$

# Regressão Linear

Regressão linear refere-se ao ajustamento por uma reta de acordo com o critério dos mínimos quadrados. A função que procuramos é

$$g(x) = a_0 + a_1x,$$

e o que pretendemos é minimizar

$$R(a_0, a_1) = \sum_{i=1}^n (y_i - a_0 - a_1x_i)^2.$$

função de duas variáveis. Logo, para minimizar basta encontrar  $a_0$  e  $a_1$  tal que:

$$\begin{cases} \frac{\partial R}{\partial a_0} = 0 \\ \frac{\partial R}{\partial a_1} = 0 \end{cases}.$$

# Regressão Linear

O algoritmo do método dos mínimos quadrados para a regressão linear consiste em estabelecer e resolver o seguinte **sistema normal**

$$\begin{bmatrix} \sum 1 & \sum x \\ \sum x & \sum x^2 \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \end{bmatrix} = \begin{bmatrix} \sum y \\ \sum xy \end{bmatrix}.$$

**Nota 1:** Havendo pelo menos dois pontos com abcissas distintas, o sistema normal é possível e determinado.

**Nota 2:** A solução é minimizante de  $R(a_0, a_1)$ .

## Example

Considerando os seguintes 5 pares ordenados  $(0.013, 0.11)$ ,  $(0.024, 0.23)$ ,  $(0.038, 0.33)$ ,  $(0.048, 0.45)$ ,  $(0.067, 0.58)$  qual é a função proveniente da regressão linear?

Solução:  $g(x) = 0.008956 + 8.712x$ .

# Regressão Linear

Para que passe na origem, a função de ajustamento seria  $g(x) = mx$  e, assim, teríamos de minimizar

$$R(m) = \sum_{i=1}^n (y_i - mx_i)^2$$

De seguida, teríamos a resolução de

$$\frac{\partial R}{\partial m} = 0 \Leftrightarrow m = \frac{\sum xy}{\sum x^2}.$$

## Theorem

*A reta de regressão linear  $y = a_0 + a_1x$  passa pelo ponto  $M$ , de coordenadas  $(\bar{x}, \bar{y})$ .*

Nota: Se trocarmos as variáveis  $x$  por  $y$ , a reta de regressão proveniente desta troca não irá coincidir com a inicial a menos que  $R = 0$ .

# Regressão Linear como $\mathbf{AX} = \mathbf{B}$

O problema consiste em encontrar uma solução de mínimos quadrados para o sistema  $\mathbf{AX} = \mathbf{B}$ :

$$\begin{bmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \end{bmatrix} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}$$

e a sua solução vem de resolver

$$\mathbf{A}' \cdot \mathbf{A} \begin{bmatrix} a_0 \\ a_1 \end{bmatrix} = \mathbf{A}' \cdot \mathbf{B} \quad \text{onde} \quad \mathbf{A}' \cdot \mathbf{A} = \begin{bmatrix} \sum 1 & \sum x \\ \sum x & \sum x^2 \end{bmatrix}, \quad \mathbf{A}' \cdot \mathbf{B} = \begin{bmatrix} \sum y \\ \sum xy \end{bmatrix}.$$

## Corollary

$\mathbf{X}$  é solução de mínimos quadrados do sistema  $\mathbf{AX} = \mathbf{B}$  sse é solução de  $\mathbf{A}'\mathbf{AX} = \mathbf{A}'\mathbf{B}$ .



# Regressão quadrática

Encontrar polinómio  $a_0 + a_1x + a_2x^2$  que se ajuste aos dados. Neste caso, pretendemos encontrar a solução de mínimos quadrados do sistema:

**$AX = B$ :**

$$\begin{bmatrix} 1 & x_1 & x_1^2 \\ 1 & x_2 & x_2^2 \\ \vdots & \vdots & \vdots \\ 1 & x_n & x_n^2 \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ a_2 \end{bmatrix} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}$$

e a sua solução vem de resolver

$$\mathbf{A}' \cdot \mathbf{A} \begin{bmatrix} a_0 \\ a_1 \\ a_2 \end{bmatrix} = \mathbf{A}' \cdot \mathbf{B} \quad \text{onde} \quad \mathbf{A}' \cdot \mathbf{A} = \begin{bmatrix} \sum 1 & \sum x & \sum x^2 \\ \sum x & \sum x^2 & \sum x^3 \\ \sum x^2 & \sum x^3 & \sum x^4 \end{bmatrix}$$

$$, \quad \mathbf{A}' \cdot \mathbf{B} = \begin{bmatrix} \sum y \\ \sum xy \\ \sum x^2y \end{bmatrix}.$$

# Regressão quadrática

## Example

Dada a tabela

x	y
0	2
2	4
4	6
6	12

determine um polinómio, de grau máximo e não superior a 2, que se ajusta aos pontos tabelados, segundo o critério de mínimos quadrados.

Solução:  $2.2 + 0.1x + 0.25x^2$

# Outras regressões

De forma análoga, podemos fazer regressão cúbica, etc. No entanto, devemos notar que se houver muitos dados fornecido (matriz **A** é grande) ou se o polinómio for de grande ordem (**A'A** grande), os sistemas **A'AX = A'B** costumam estar mal condicionados.

# Definição

## Definition

Um polinómio  $p(x)$  de grau  $n - 1$  diz-se **interpolador de um conjunto de  $n$  pontos**  $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$  se

$$\forall i = 1, \dots, n : p(x_i) = y_i.$$

Este polinómio interpolador, será o polinómio de menor grau que interpola os pontos.

É usual chamar aos  $x_i$  nós ou nodos da interpolação e valores nodais aos  $y_i$ .

São habitualmente utilizados para estimar  $f(\hat{x})$  para um  $\hat{x} \neq x_i$ , não se sabendo para já sobre a qualidade desta estimativa/aproximação.

# Definição

## Example

$$p_1(x) = 2x + 1$$

$$p_2(x) = 2x^2 + 1$$

$$p_3(x) = -2x^2 + 4x + 1$$

são polinómios interpoladores dos pontos tabelados:

x	y
0	1
1	3

Se quiséssemos aproximar  $f(0.8)$  através de  $p_i(0.8)$ , obteríamos valores diferentes em cada caso.

# Definição

Se na tabela existirem dois pontos iguais, ou seja, para  $i \neq j$  temos  $(x_i, y_i) = (x_j, y_j)$ , dever-se-á retirá-lo pois está repetido.

Se para certos  $i \neq j$ , tivermos  $x_i \neq x_j$  mas, no entanto,  $y_i = y_j$ , então não existe polinómio interpolador para o conjunto de pontos dado.

O objetivo resume-se a resolver

$$\begin{bmatrix} 1 & x_1 & \dots & x_1^k \\ 1 & x_2 & \dots & x_2^k \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_n & \dots & x_n^k \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ \dots \\ a_k \end{bmatrix} = \begin{bmatrix} y_1 \\ y_2 \\ \dots \\ y_n \end{bmatrix}.$$

# Exemplo sem fórmula geral

## Example

Considerando a tabela seguinte de valores de uma função  $y = f(x)$ .

x	y
1.0	0.84
1.3	0.96
1.9	0.95

Determine o polinómio, de grau mínimo, que interpola os pontos.

Determine um valor aproximado de  $f(1.65)$ . Sabendo que na verdade

$f(x) = \sin(x)$ , determine o erro relativo da interpolação anterior.

Solução:  $p(x) = -0.162 + 1.465x - 0.463x^2$  polinómio de grau 2.

$f(1.65) \approx p(1.65) = 0.995$

Estimativa do erro relativo, sabendo que

$f(1.65) = \sin(1.65) = 0.996865\dots$ :

$$\delta = \frac{|0.9969 - 0.995|}{|0.9969|} = 0.0019(0.19\%)$$

# Teorema da existência

## Theorem

*Sejam  $(x_1, y_1), \dots, (x_n, y_n)$  um conjunto de  $n$  pares ordenados com  $x_i \neq x_j$ ,  $\forall i \neq j$ , então o sistema de equações lineares*

$$\begin{bmatrix} 1 & x_1 & \dots & x_1^k \\ 1 & x_2 & \dots & x_2^k \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_n & \dots & x_n^k \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ \dots \\ a_k \end{bmatrix} = \begin{bmatrix} y_1 \\ y_2 \\ \dots \\ y_n \end{bmatrix}.$$

- *no caso de  $k < n - 1$ , só tem solução para determinados valores de  $y_i$ . Quando a solução existe, é única. Quando não existe, procura-se uma solução de mínimos quadrados;*
- *no caso de  $k = n - 1$ , tem sempre solução e esta é única;*
- *no caso de  $k \geq n$ , tem solução e para cada solução  $p(x)$ , os polinómios  $p(x) + (x - x_1)(x - x_2) \dots (x - x_n) \cdot r(x)$  são também soluções.*



# Interpolação de Lagrange

O polinómio interpolador segundo a fórmula de interpolação de Lagrange será dado por:

$$p(x) = \sum_{k=1}^n y_k \cdot L_k(x)$$

onde os **polinómios de Lagrange** são:

$$L_k(x) = \frac{\prod_{l=1, l \neq k}^n (x - x_l)}{\prod_{l=1, l \neq k}^n (x_k - x_l)}.$$

# Exemplo

## Example

Considerando a tabela seguinte de valores de uma função  $y = f(x)$ .

x	y
1	25
3	38
4	45
7	40
8	58

Determine um valor aproximado de  $y$  para  $x = 7.4$ , usando uma interpolação linear:

Para a interpolação linear, o polinómio interpolador segundo a fórmula de Lagrange será obtido através de linear

$$p_1(x) = L_1(x)y_1 + L_2(x)y_2 = \frac{x-x_2}{x_1-x_2}y_1 + \frac{x-x_1}{x_2-x_1}y_2.$$

# Exemplo

## Example

Vamos escolher os dois últimos para interpolar  $x = 7.4$ ; o critério da escolha dos pontos será desenvolvido aquando do estudo do erro da interpolação.

$$p_1(x) = \frac{x-8}{7-8} \times 40 + \frac{x-7}{8-7} \times 58$$

$$f(7.4) \approx p(7.4) = \frac{7.4-8}{-1} \times 40 + \frac{7.4-7}{1} \times 58 = 47.2$$

Se quiséssemos um interpolador quadrático teríamos

$$p_2(x) = \frac{(x-x_2)(x-x_3)}{(x_1-x_2)(x_1-x_3)}y_1 + \frac{(x-x_1)(x-x_3)}{(x_2-x_1)(x_2-x_3)}y_2 + \frac{(x-x_1)(x-x_2)}{(x_3-x_1)(x_3-x_2)}y_3$$

$$p_2(7.4) = \frac{(7.4-7)(7.4-8)}{(4-7)(4-8)}45 + \frac{(7.4-4)(7.4-8)}{(7-4)(7-8)}40 + \frac{(7.4-4)(7.4-7)}{(8-4)(8-7)}58 = 46$$

# Diferenças divididas

A fórmula de Lagrange envolve demasiados produtos e quocientes comprometendo a estabilidade do método. Usando o polinómio interpolador, na forma de Lagrange, para uma interpolação com  $n$  nós, se quisermos adicionar um nó, todo o trabalho feito terá de ser perdido. O mesmo não acontece com a forma de Newton que iremos explicar.

## Theorem

*Se tivermos à partida o polinómio  $p_{n-1}(x)$ , então*

$$p_n(x) = p_{n-1}(x) + a_n(x - x_1) \dots (x - x_n)$$

*onde*

$$a_n = \frac{y_{n+1} - p_n(x_{n+1})}{(x_{n+1} - x_1)(x_{n+1} - x_2) \dots (x_{n+1} - x_n)}$$

*e onde  $y_{n+1} = p_n(x_{n+1}) = f(x_{n+1})$ .*

# Diferenças divididas

## Definition

- Diferença dividida de ordem 0 da função  $f$ , relativamente a  $x_i$ , é

$$\Delta^0 y[x_i] = y_i$$

- De ordem 1, relativamente a  $x_i$  e  $x_j$ , é

$$\Delta^1 y[x_i, x_j] = \frac{y_j - y_i}{x_j - x_i}$$

- De ordem 2, relativamente a  $x_i$ ,  $x_{i+1}$  e  $x_{i+2}$ , é

$$\Delta^2 y[x_i, x_{i+1}, x_{i+2}] = \frac{\Delta^1 y[x_{i+1}, x_{i+2}] - \Delta^1 y[x_i, x_{i+1}]}{x_{i+2} - x_i}$$

# Diferenças divididas

## Definition

- Diferença dividida de ordem  $n$  da função  $f$ , relativamente a  $x_i$ ,  $x_{i+1}$ , ...,  $x_{i+n}$ , é

$$\Delta^n y[x_i, \dots, x_{i+n}] = \frac{\Delta^{n-1} y[x_{i+1}, \dots, x_{i+n}] - \Delta^{n-1} y[x_i, \dots, x_{i+n-1}]}{x_{i+n} - x_i} =$$

- Diferença dividida de ordem  $n - 1$  da função  $f$ , relativamente a  $x_1$ ,  $x_2$ , ...,  $x_n$ , é

$$\Delta^{n-1} y[x_1, \dots, x_n] = \sum_{k=1}^n \left( y_k \prod_{l=1, l \neq k}^n \frac{1}{x_k - x_l} \right)$$

# Diferenças divididas

O polinómio interpolador dos valores  $(x_1, y_1), \dots, (x_n, y_n)$  pode-se escrever através da fórmula de interpolação com diferenças divididas, chamada forma de Newton, como:

$$p_n(x) = \Delta^0 y[x_1] + \Delta^1 y[x_1, x_2](x - x_1) + \Delta^2 y[x_1, x_2, x_3](x - x_1)(x - x_2) \\ + \dots + \Delta^{n-1} y[x_1, \dots, x_n] \prod_{i=1}^{n-1} (x - x_i)$$

## Example

Considerando  $y = f(x)$ , tabelada como:

$x$	0	1	3	4	7	9
$f(x)$	0	1	1.73	2	2.65	3

Qual o valor de  $f(4.4)$ ?

# Diferenças divididas

## Example

Começemos por construir uma tabela com todas as diferenças divididas calculadas recursivamente:

$x$	$f(x) = \Delta^0 y$	$\Delta^1 y$	$\Delta^2 y$	$\Delta^3 y$	$\Delta^4 y$	$\Delta^5 y$
4	2	0.27	-0.0133	0.00307	-0.00603	0.000642
3	1.73	0.23	-0.0225	0.0272	-0.00282	
7	2.65	0.275	-0.104	0.0103		
1	1	1	-0.0834			
0	0	0.333				
9	3					

$$p_1(x) = y_1 + \Delta^1 y[x_1, x_2](x - x_1) = 2 + 0.27(x - 4)$$

$$p_2(x) = y_1 + \Delta^1 y[x_1, x_2](x - x_1) + \Delta^2 y[x_1, x_2, x_3](x - x_1)(x - x_2) = 2 + 0.270(x - 4) - 0.0133(x - 4)(x - 3)$$

$$p_3(x) = 2 + 0.270(x - 4) - 0.0133(x - 4)(x - 3) + 0.00307(x - 4)(x - 3)(x - 7)$$

etc...



# Erro

Depois de considerar o teorema

## Theorem

*Dados os pontos  $x_i \in [a, b], i = 1, \dots, n$  reais diferentes, dada uma função  $f(x)$  com derivada contínua até ordem  $n - 1$ , então  $\exists c \in [a, b]$ :*

$$f^{(n-1)}(c) = (n-1)! \Delta^{n-1} y[x_1, \dots, x_n]$$

A fórmula do erro de  $p(x)$  como aproximação de  $f(x)$  é dada por

$$E(f(x), p(x)) = \left| \frac{f^{(n)}(c)}{n!} (x - x_1)(x - x_2) \dots (x - x_n) \right|$$

Nota:  $\Delta^{n-1} y[x_1, \dots, x_n]$  serão então aproximações de  $\frac{f^{(n-1)}(x)}{(n-1)!}$  para valores em  $[a, b]$ .

# Diferenças finitas

Se as abcissas forem igualmente espaçadas, ou seja,

$$h = x_{i+1} - x_i = \frac{x_n - x_1}{n - 1}$$

a **diferença finita** de ordem 1 será:

$$\Delta^1 y_i = y_{i+1} - y_i$$

de ordem 2

$$\Delta^2 y_i = \Delta^1(\Delta^1 y_i) = \Delta^1 y_{i+1} - \Delta^1 y_i$$

de ordem k (inteiro não negativo)

$$\Delta^k y_i = \Delta^1(\Delta^{k-1} y_i) = \Delta^{k-1} y_{i+1} - \Delta^{k-1} y_i = k! \times h^n \times \Delta^k y[x_i, \dots, x_{i+k}]$$

tendo para  $k = 0$ ,  $\Delta^0 y_i = y_i$ . E, dessa forma, pode-se escrever

$$p(x) = y_i + \sum_{i=1}^{n-1} \left( \prod_{k=1}^i (x - x_k) \right) \frac{\Delta^i y_i}{i! \times h^n}$$

# Diferenças finitas

## Example

x	y	$\Delta$	$\Delta^2$	$\Delta^3$	$\Delta^4$
2	13				
		65			
3	78		110		
		175		84	
4	253		194		24
		369		108	
5	622		302		
		671			
6	1293				

$$p_2(x) = 13 + (x - 2) \times \frac{65}{1! \times 1} + (x - 2)(x - 3) \times \frac{110}{2! \times 1^2}$$

$$p_2^*(x) = 78 + (x - 3) \times \frac{175}{1! \times 1} + (x - 3)(x - 4) \times \frac{194}{2! \times 1^2}$$

# Derivação numérica

Tendo em conta o seguinte resultado:

$$f(x) - p_{n-1}(x) = \frac{f^n(c)}{n!} (x - x_1)(x - x_2) \dots (x - x_n)$$

é equivalente a dizer que

$$f(x) = p_{n-1}(x) + \frac{f^n(c)}{n!} \prod_{i=1}^n (x - x_i)$$

e daí podemos concluir que

$$f'(x) = p'_{n-1}(x) + \frac{f^n(c)}{n!} \prod_{i=1}^{n-1} (x - x_i)$$

para valores  $x$  no intervalo que contem os pontos  $x_i$ . Portanto, podemos agora criar várias fórmulas para calcular  $f'(a)$ .

# Derivação numérica

Com dois pontos  $x_1 = a$ ,  $x_2 = a + h$ :

$$f'(a) = \frac{1}{h}(f(a) - f(a + h)) - \frac{h}{2}f''(c), c \in [a, a + h]$$

Com dois pontos  $x_1 = a - h$ ,  $x_2 = a$ :

$$f'(a) = \frac{1}{h}(f(a - h) - f(a)) - \frac{h}{2}f''(c), c \in [a - h, a]$$

Com três pontos  $x_1 = a - h$ ,  $x_2 = a$  e  $x_3 = a + h$ :

$$f'(a) = \frac{1}{2h}(f(a + h) - f(a - h)) - \frac{h^2}{6}f'''(c), c \in [a - h, a + h]$$